



DataScientest • com

Analyse de ventes e-commerce

Projet RFM

Rapport Technique d'évaluation



Formation continue Data analyst – Promotion avril 2022

Virginie BOULAND

Nathalie CLAUDE

Olivier BONNIN

Table des matières

I.	Contexte du projet	3
1.	Contexte d'insertion du projet dans votre métier.....	3
2.	Du point de vue technique :.....	3
3.	Du point de vue économique :	4
4.	Du point de vue scientifique :	5
II.	Objectifs	5
1.	Principaux objectifs du projet	5
2.	Intégration du projet dans un cadre professionnel réel	5
III.	Preprocessing	6
1.	Présentation des données utilisées	6
2.	Preprocessing – Visualisation, exploration et nettoyage des données	6
a.	Visualisation et nettoyage des données	6
b.	Gestion des NaN	7
c.	Formatage	8
d.	Redéfinition des valeurs de certaines variables	8
e.	Gestion du cours de change.....	8
3.	Statistiques exploratoires	9
a.	Matrice de corrélation	9
b.	Tests ANOVA	10
c.	Tests de Khi2 et V de Cramer	10
d.	Test de Pearson.....	10
e.	Conclusion des tests statistiques	10
4.	Études complémentaires	11
a.	Etude de la variable « Regroupement_status ».....	11
b.	Étude de la variable « Price_euros ».....	12
c.	Étude chronologique des « Regroupement_status »	13
d.	Etudes des méthodes de paiement	14
e.	Étude chronologique des ventes	15
f.	Etude de la linéarité de la relation entre « Price_euros » et « Net_income_euros »	15
IV.	Segmentation RFM.....	16

1.	Projet – Algorithme mis en oeuvre	16
a.	Principe de la méthode RFM.....	16
2.	Segmentation RFM.....	16
a.	Modèles testés.....	16
3.	Choix du modèle	18
4.	Application du modèle RFM au dataset.....	18
V.	Description des travaux réalisés.....	21
1.	Organisation de l'équipe.....	21
2.	Problématiques rencontrées lors du projet.....	21
a.	Problématiques scientifiques.....	21
b.	Gestion des tâches et du jeu de données	21
c.	Compétences techniques et théoriques	21
d.	Limitations liées aux ressources IT.....	21
VI.	Bilan & Suite du projet	22
1.	Intérêt scientifique du projet.....	22
2.	Réussite et bilan	22
3.	Possibilité de mise en œuvre dans en entreprise	23
4.	Axes de développements futurs	23
	Bibliographie	24

I. Contexte du projet

1. Contexte d'insertion du projet dans votre métier.

■ Virginie Bouland :

Voici mon métier de TEM (Telecom Expense Management) analyste : traiter (des datas), analyser, produire (études, rapports.), préconiser et accompagner mes clients dans l'optimisation des coûts de leur flotte mobile. Mes outils : Excel et Power Point.

Ce projet sera le 1er livrable (post formation) que je présenterai à ma direction. Il me permettra de justifier du choix de cette formation et de recueillir les premières appréciations sur ce type de présentation.

■ Nathalie Claude :

Je suis actuellement technicienne d'exploitation vidéo pour une chaîne de télévision. Ce projet s'inscrit dans le cadre d'une démarche de reconversion totale, qui n'a aucun lien avec mon domaine d'expertise actuel.

Je compte utiliser ce projet dans la continuité de ma formation pour acquérir un maximum d'expérience, d'automatismes, et de nouvelles compétences pour enrichir mon bagage professionnel.

■ Olivier Bonnin :

Expert-comptable et manager en cabinet d'audit de d'expertise-comptable, je développe actuellement un pôle axé sur la mise en œuvre d'une démarche de business intelligence à destination : des clients du cabinet (conseil, reporting) et des équipes d'audit.

La formation entre dans le cadre du développement de nouvelles compétences personnelles afin de répondre aux évolutions de mon métier (digitalisation, automatisation) afin de proposer de nouvelles offres de services.

2. Du point de vue technique :

■ Virginie Bouland :

Ce projet est un passage de la théorie à la pratique. Les soucis techniques rencontrés avec le projet ont été l'occasion d'approfondir les connaissances apportées par la formation. Le travail en équipe a été enrichissant.

■ Nathalie Claude :

Il n'y a aucune passerelle entre mon métier actuel et le domaine de la data, que ce soit d'un point de vue codage, data visualisation, utilisation de logiciels bureautiques (power BI, Tableau).

Si je parviens à me reconvertir, et à trouver emploi dans la data, ce sera un renouvellement technique complet pour moi. Ces nouvelles compétences techniques ajoutées à celles déjà existantes me fournissent un bagage lourd et puissant sur un CV.

Cependant, l'idéal (bien que peu probable), serait de pouvoir combiner mes compétences techniques déjà en ma possession à celles nouvellement acquises grâce à cette formation.

De plus, à l'image de la formation, les métiers de la data sont totalement compatibles avec le télétravail. C'est-à-dire que je peux mener à bien un projet en équipe, sans perte d'efficacité. Et ça, ça représente un avantage considérable.

- Olivier Bonnin :

Déjà utilisateur quotidien de Power Bi, je suis techniquement limité à l'utilisation du logiciel sans pouvoir travailler les données en amont de l'intégration des données dans le logiciel. La formation me permet d'acquérir les compétences nécessaires dans l'extraction, le preprocessing, l'analyse des données. La formation me permet d'acquérir une réelle compétence professionnelle sur le domaine de l'analyse de données, de professionnaliser et développer mes compétences en la matière.

3. Du point de vue économique :

- Virginie Bouland :

Il n'était pas prévu pour la PME qui m'emploie d'avoir recours à un data analyst. Cependant au terme de cette formation, je vais réaliser un gain de productivité qui me permettra d'absorber une augmentation de mon portefeuille client.

De plus, la modernisation de mes présentations sera aussi valeur ajoutée supplémentaire pour l'entreprise qui se démarquera en avance de phase de ses confrères.

- Nathalie Claude :

Les métiers de la data sont en pleine émergence et en constante évolution, il y a une très forte demande, même pour des postes juniors. Cela limite les risques liés généralement à une démarche de reconversion.

De plus, je compte m'appuyer sur ma déjà longue expérience professionnelle pour crédibiliser au mieux mon statut de data analyste junior.

- Olivier Bonnin :

L'évolution de mon métier, de plus en plus digitalisé et axé sur l'analyse de données en est encore à ses débuts mais prends énormément d'ampleur avec l'émergence des fintech. La formation me permet de développer un nouveau pôle dans min cabinet mais également de valoriser mes compétences sur le marché du travail avec un profil encore peu répandu (expert-comptable et data analyste à la fois).

4. Du point de vue scientifique :

- Virginie Bouland :

La formation a complété mes connaissances en statistiques et m'a apporté de nouvelles approches dans l'analyse et la visualisation.

- Nathalie Claude :

Cette formation m'a permis de revoir des notions mathématiques et statistiques vues lors de mon parcours scolaire, de mieux les maîtriser, et d'en aborder de nouvelles.

Les notions de codage que je possédais déjà m'ont aussi été d'une grande aide.

- Olivier Bonnin :

La formation me permet une réelle remise à niveau et un développement en termes : de connaissances statistiques, d'analyses chiffrées et d'interprétation de données.

II. Objectifs

1. Principaux objectifs du projet

Notre projet consiste à l'analyse des données d'un site de e-commerce en vue de la **mise en place d'une démarche de clustering basée sur une segmentation « Recency, Frequency, Monetary » (« RFM »)** de la clientèle du site.

Pour ce faire, nos objectifs sont de :

- Nettoyer le dataset (preprocessing) ;
- Etudier les différentes variables du dataset afin d'orienter le projet ;
- Segmenter, appliquer et tester des méthodes de clustering RFM.

L'objectif final de notre démarche est ainsi de proposer des stratégies, principalement marketing, permettant au site de développer son chiffre d'affaires.

2. Intégration du projet dans un cadre professionnel réel

- Virginie Bouland :

A ma connaissance, ce projet n'est pas d'actualité. Cependant le scoring utilisé peut être réadapté pour traiter des sujets autres que la RFM. Ainsi, je prévois d'ajuster le modèle aux consommations des lignes mobiles (voix, data, SMS) et / ou des zones de consommations qui me permettront pour chaque cluster de proposer une solution personnalisée.

- Nathalie Claude :

En ce qui me concerne, je n'ai pas connaissance d'un tel projet au sein de mon entreprise.

- Olivier Bonnin :

Dans le cadre du développement de mon nouveau pôle « Bi », nous mettons actuellement en place un reporting mensuel axé business pour une chaîne de restauration rapide. Il se concentre sur une analyse du passé pour un meilleur pilotage du futur. Il m'apparaît aujourd'hui pertinent de proposer au client d'effectuer une analyse des données clients dont il dispose afin de pouvoir effectuer une segmentation de sa clientèle visant à aider à la mise d'une stratégie marketing adaptée à cette dernière.

III. Preprocessing

1. Présentation des données utilisées

L'ensemble du projet est basé sur un jeu de données résumant des transactions de commerce électronique au Pakistan sur la période mars 2016 à août 2018.

Ce jeu de données est disponible en open-source sur internet par le biais du site internet Kaggle¹. Il a été conçu et mis à disposition par M^r Zeeshan-ul-hassan Usmani dans une optique de démarche collaborative afin d'analyser le dataset.

Se présentant sous la forme d'un fichier « csv » (Comma-separated values), composé de plus d'un million de lignes, le jeu de données présente un volume de 106 Mb.

2. Preprocessing – Visualisation, exploration et nettoyage des données

a. Visualisation et nettoyage des données

La version brute du dataset était difficilement exploitable en l'état, à cause d'un nombre important de données incomplètes ou inutiles, de formats de données inadaptés, et d'un besoin d'harmonisation général.

	item_id	status	created_at	sku	price	qty_ordered	grand_total	increment_id	category_name_1	sales_commission_code	discount_amou
0	211131.0	complete	7/1/2016	kreations_YI 06-L	1950.0	1.0	1950.0	100147443	Women's Fashion	NaN	
1	211133.0	canceled	7/1/2016	kcc_Buy 2 Frey Air Freshener & Get 1 Kasual Bo...	240.0	1.0	240.0	100147444	Beauty & Grooming	NaN	
2	211134.0	canceled	7/1/2016	Ego_UP0017- 999-MR0	2450.0	1.0	2450.0	100147445	Women's Fashion	NaN	
3	211135.0	complete	7/1/2016	kcc_krone deal	360.0	1.0	60.0	100147446	Beauty & Grooming	R-FSD-52352	300
4	211136.0	order_refunded	7/1/2016	BK7010400AG	555.0	2.0	1110.0	100147447	Soghaat	NaN	

¹ Kaggle : <https://www.kaggle.com/datasets/zusmani/pakistans-largest-ecommerce-dataset>

Il a donc fallu un important travail de preprocessing.

Après une première exploration du jeu de données nous avons effectué les observations suivantes :

- Plages de données vides : les 5 dernières colonnes du jeu de données (nommées « Unnamed ») ainsi que près de 464 051 ne présentent aucune donnée (NaN). Ces colonnes et lignes ont été supprimées du dataset ;
- Données redondantes : 'FY' et 'M-Y' sont des données redondantes compte tenu de la présence de la date complète des opérations dans le dataset. Nous avons donc choisi de supprimer ces données.
- Colonnes non pertinentes : après avoir identifié le sens des informations contenues dans les colonnes 'sku' et 'Working Date', nous les avons jugées non pertinentes pour notre analyse et les avons donc supprimées ;

b. Gestion des NaN

A cette étape, nous avons un dataframe ne regroupant que les données qui nous semblent pertinentes pour notre analyse et pouvons donc continuer le preprocessing avec la gestion des valeurs vides « NaN » (« Not a Number »).

- Customer_id : dans la mesure où le projet RFM se base sur les comportements clients, nous avons supprimé l'ensemble des entrées incomplètes liées aux variables « cust_id ». Cette approche s'appuie sur le fait que le numéro client ne peut être complété par une approche statistique (le mode ne permet pas de remplacer les NaN par une donnée satisfaisante).
- Sales commission code (id_magasin) : de la même manière nous avons opté pour la suppression de l'ensemble des lignes ne renseignant pas d'id. Il s'agit d'une donnée qui pourrait porter un intérêt pour notre analyse, et qui est là encore non remplaçable de manière pertinente.

A ce stade nous constatons qu'il reste simplement 1 610 des NaN dans la colonne « Category ». Ces données représentant 0,27 % des données du dataset, et la catégorie de produit acheté étant une des composantes importantes de l'analyse du comportement client, nous décidons là aussi de supprimer les NaN.

⇒ **Après ces opérations le dataset ne présente plus de NaN et est donc complet.**

c. Formatage

Dans un deuxième temps nous avons procédé à un formatage des données afin de permettre une bonne manipulation des variables lors de la mise en œuvre de notre analyse RFM :

Dataframe avant formatage

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 106738 entries, 0 to 106737
Data columns (total 16 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Customer id           106738 non-null float64
1   Customer since        106738 non-null object
2   Item_id               106738 non-null float64
3   Increment_id          106738 non-null object
4   Sales_commission_code 106738 non-null object
5   Qty_ordered           106738 non-null float64
6   Price                 106738 non-null float64
7   Discount_amount       106738 non-null float64
8   Grand_total           106738 non-null float64
9   Payment_method        106738 non-null object
10  Created_at            106738 non-null object
11  Year                  106738 non-null float64
12  Month                 106738 non-null float64
13  Category_name_1       106738 non-null object
14  Bi_status             106738 non-null object
15  Status                106738 non-null object
dtypes: float64(8), object(8)
memory usage: 13.8+ MB
```

Dataframe formaté

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 106738 entries, 0 to 106737
Data columns (total 16 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Customer_id           106738 non-null object
1   Customer since        106738 non-null period[M]
2   Item_id               106738 non-null object
3   Increment_id          106738 non-null int64
4   Sales_commission_code 106738 non-null object
5   Qty_ordered           106738 non-null int64
6   Price                 106738 non-null float64
7   Discount_amount       106738 non-null float64
8   Net_income            106738 non-null float64
9   Payment_method        106738 non-null object
10  Created_at            106738 non-null datetime64[ns]
11  Year                  106738 non-null int64
12  Month                 106738 non-null int64
13  Category              106738 non-null object
14  Bi_status             106738 non-null object
15  Status                106738 non-null object
dtypes: datetime64[ns](1), float64(3), int64(4), object(7), period[M](1)
memory usage: 13.8+ MB
```

⇒ **A ce stade l'ensemble des variables ont été mises au format adéquat.**

d. Redéfinition des valeurs de certaines variables

Lors de notre analyse nous avons constaté un nombre important de valeurs uniques dans les statuts et méthodes de paiement. Pour une meilleure lecture nous avons ainsi procédé au retraitement de ces variables comme suit :

- Statuts : nous avons regroupé les variables en trois groupes « finalisé », « en attente » et « clôturé » afin de créer trois valeurs homogènes de statuts ;
- Méthode de paiement : nous avons regroupé les valeurs uniques en 5 grandes méthodes de paiement homogènes « cod (cash on delivery) », « paiement immédiat », « paiement en plusieurs fois », « voucher », et « portefeuille en ligne ».

e. Gestion du cours de change

L'ensemble des opérations sont libellées en roupies pakistanaïses (« PKR »), et nous décidons donc, pour une meilleure lisibilité des données de convertir l'ensemble des données monétaires en euros.

Dans le cadre cette opération de conversion nous avons ainsi eu recours au package easy-exchange-rates de python et à son « API » (Application Protocol Interface).


Nous avons donc ajouté au dataset le cours journalier de chacune des opérations et avons par la suite converti l'ensemble des opérations en euros dans des colonnes dédiées.

3. Statistiques exploratoires

Nous avons effectué différents tests statistiques afin d'étudier les relations entre les différentes variables.

a. Matrice de corrélation

Pour l'analyse des variables numériques nous avons effectué une matrice de corrélation :



⇒ La matrice met en évidence une relation entre « Net_income_euros » et « Price_euros ».

b. Tests ANOVA

Nous avons effectué des tests ANOVA afin d'étudier les relations suivantes :

- « Price_euros » et « Category » qui remonte une p-value à 0 indiquant que les deux variables ne sont pas indépendantes ;
- « Net_income_euros » et « Category » qui remonte une p-value proche de 0 traduisant que la variable « Category » a un effet statistique significatif sur la variable « Net_income_euros » ;
- « Quantity_ordered » et « Category » qui remonte une p-value proche de 0 traduisant que la variable « Category » a un effet statistique significatif sur la variable « Quantity_ordered ».

c. Tests de Khi2 et V de Cramer

Nous avons effectué des tests de Khi2 et V de Cramer afin d'étudier les relations suivantes :

- « Category » et « Customer_id » : le Khi2 remonte une p-value de 0, et le coefficient de Cramer est de 0,44, ce qui traduit que les variables ne sont pas fortement corrélées. Cependant cette corrélation n'est pour autant pas négligeable ;
- « Sales_commissions » et « Customer_id » : le Khi2 remonte une p-value de 0 et le coefficient de Cramer est de 0,62, ce qui traduit que les variables sont corrélées entre elles ;

d. Test de Pearson

Pour l'analyse des variables « Net_income_euros » et « Customer_id » nous avons effectué un test de Pearson qui remonte un coefficient proche de 0 et une p-value inférieure à 5 %, ce qui traduit une absence de corrélation. En revanche il y a un effet statistique non négligeable entre ces deux variables.

e. Conclusion des tests statistiques


Nos tests nous permettent de conclure à une **corrélation des différentes variables catégorielles et continues étudiées**.

Compte tenu de la grande variété du jeu de données, il nous est permis d'envisager plusieurs profils d'études / de variables cibles. Cependant dans le cadre de notre étude RFM, notre cible reste « Customer_id ».

4. Études complémentaires


a. Étude de la variable « Regroupement_status »

Nous avons effectué une analyse des statuts des transactions par catégorie de produits vendus :




⇒ Notre analyse permet de conclure sur le fait que l'ensemble des catégories sont impactées par des taux d'annulations de commandes variant de 16 % à 56%.

b. Étude de la variable « Price_euros »



⇒ L'étude de cette variable remonte de nombreuses valeurs extrêmes. Pour les extrêmes positifs il s'agit de commandes annulées et remboursées. En revanche nous constatons des transactions à 0 euros que nous décidons de supprimer car nous ne justifions pas la présence de ces transactions qui dégradent la visualisation des données.


c. Étude chronologique des « Regroupement_status »



⇒ Entre 2016 et 2018 nous constatons une évolution négative de 12,73% des commandes finalisées et en moyenne 35,63 % des commandes ont été annulées.

Les commandes en attente apparaissant en 2017 sont négligeables (moins de 1%).

d. Etudes des méthodes de paiement



⇒ Les années 2016 et 2017 mettent en évidence une dominance du paiement « cash on delivery ». En 2018 nous constatons une plus grande hétérogénéité des moyens de paiement, exception faite du paiement par le biais de portefeuilles en ligne qui tend à disparaître.


e. Étude chronologique des ventes



⇒ Nous constatons qu'en dehors de l'exercice 2017 qui présente des pics d'activité, le chiffre d'affaires est relativement homogène. Compte tenu de l'évolution moindre de la médiane comparativement à la moyenne, nous concluons qu'il s'agit d'un nombre restreint de transactions qui entraînent une hausse ponctuelle de ce dernier.

f. Etude de la linéarité de la relation entre « Price_euros » et « Net_income_euros »

Par ailleurs, nous avons appliqué un modèle de régression linéaire aux ventes afin de vérifier la linéarité entre « Price_euros » et « Net_income_euros ».



⇒ Nous constatons que les valeurs aberrantes n'avaient pas d'influence significative sur la relation linéaire liant les deux variables.

IV. Segmentation RFM

1. Projet – Algorithme mis en oeuvre

a. Principe de la méthode RFM

La méthode RFM consiste à regrouper les clients faisant l'objet de l'étude, en fonction du calcul d'un score et s'apparente à un modèle de classification.

Il a pour tâche l'évaluation automatisée des clients du site de e-commerce afin de permettre une analyse des comportements par cluster en fonction de :

- Recency : date du dernier achat ;
- Frequency : nombre d'achats effectués sur une période déterminée ;
- Monetary : somme des achats cumulés sur une période déterminée.

2. Segmentation RFM

Dans un premier temps, nous avons calculé les variables Recency (nombre de jours depuis la dernière visite), Frequency (nombre de jours où le client a effectué un achat au minimum) et Monetary (total dépensé par le client).

Nous avons réuni ces données dans un dataset « df_rfm » que nous avons fusionné au dataset initial.

Si la RFM est une démarche de segmentation de la clientèle selon un score calculé, il existe plusieurs méthodes afin de la mettre en œuvre. Au cours de notre projet, après avoir réalisé une recherche sur les différents modèles possibles, nous avons retenu deux modèles que nous avons testés dans le cadre de notre projet.

a. Modèles testés

▪ **1^{er} modèle :**

Ce modèle est basé sur un calcul de pondération des trois composantes de la RFM (15% pour la récence, 28 % pour la fréquence et 57 % pour le score monétaire).

Ce calcul donne un score RFM allant de 0 à 5 et permettant une classification des clients sur la base des règles suivantes :

- $\text{rfm score} > 4.5$: Top Customer ;
- $4.5 \geq \text{rfm score} > 4$: High Value Customer ;
- $4 \geq \text{rfm score} > 3$: Medium value Customer ;
- $3 \geq \text{rfm score} > 1.6$: Low-value Customer ;
- $\text{rfm score} \leq 1.6$: Lost Customer.

L'application de ce modèle permet la création du dataframe suivant :

	Customer_id	Recency	Frequency	Monetary	R_rank_norm	F_rank_norm	M_rank_norm	RFM_Score	Customer_segment
0	4	1	392	20285.24	99.95	99.77	99.77	4.99	Top Customers
1	11	560	6	40.03	23.31	81.32	81.32	3.63	Medium Value Customer
2	13	595	192	5220.82	20.72	99.57	99.57	4.39	High value Customer
3	20	3	420	36523.91	99.87	99.80	99.80	4.99	Top Customers
4	32	12	626	40300.07	98.48	99.87	99.87	4.98	Top Customers


■ 2^{ème} modèle :

La notation (de 1 à 3) de chaque composante RFM est réalisée sur la base de quintiles et le score RFM est calculé par la concaténation des trois notes.

Dans ce modèle nous avons effectué une « clusterisation manuelle » en fonction des scores RFM, et regroupé les clients selon leurs caractéristiques :

- Top Customer : ce client achète, revient très régulièrement, et effectue des dépenses importantes ;
- Client à potentiel élevé : ce client a effectué un achat récemment, est régulier, et dépense cependant moins qu'un Top Customer ;
- Client dilemme : il s'agit d'un client qui achète et revient occasionnellement ;
- Client à surveiller : il s'agit d'un client qui n'est pas revenu récemment, qui n'est pas forcément régulier mais qui dépense plutôt des sommes importantes ;
- Client sans potentiel stratégique : ce client n'est pas venu récemment et n'est pas régulier, il n'a donc aucun intérêt stratégique, peu importe le montant de ses achats. Il pourra difficilement être fidélisé.

L'application de ce modèle fait ressortir la répartition suivante :



3. Choix du modèle

Notre métrique de performance sera évaluée par la capacité de l'algorithme à ressortir des groupes de clients homogènes et cohérents.

Nous avons retenu le deuxième modèle testé « RFM2 » pour plusieurs raisons :

- Détermination des coefficients de pondération : le 1^{er} modèle se base sur l'application de coefficients de pondération aux trois composantes de la RFM. En l'absence d'experts marketing, la définition des coefficients nous a paru assez arbitraire comparativement à la deuxième approche. Par ailleurs nous ne connaissons pas la stratégie de l'entreprise : prépondérance donnée à la fidélisation ou à l'arrivée de nouveaux clients... ;
- Interprétabilité des clusters : la composition des différents clusters regroupe différents profils définis selon une notation des clients sur une échelle de 1 à 3 plutôt que sur un score global (approche n°1). Le profilage des différents clients est ainsi rendu plus simple d'interprétation ;
- Approche comportementaliste : notre approche permet la constitution de clusters basés sur le placement du client vis-à-vis de la stratégie de la société. Ainsi le profilage des individus de chaque cluster permet d'éviter le regroupement au sein d'un même cluster de deux individus ayant un score RFM proche, malgré des profils très différents ;
- Souplesse du modèle : le modèle RFM2 étant basé sur des règles de classification prédéfinies, ces règles peuvent à tout moment être modifiées afin d'évoluer au gré de la stratégie de la société.

4. Application du modèle RFM au dataset

Après avoir appliqué notre modèle au dataset, nous sommes en mesure de préconiser à la société différents plans d'actions adaptés à chaque cluster stratégique :


TOP CUSTOMER

Nous n'effectuons pas de recommandation pour ces clients fidèles, réguliers et bons consommateurs.

CLIENTS SANS POTENTIEL STRATÉGIQUE


Nous n'effectuons aucune préconisation sur ces clients qui ne sont pas revenus récemment, ne consomment pas régulièrement et dépensent peu.

CLIENTS À POTENTIEL ÉLEVÉ




⇒ Nous souhaitons augmenter leur consommation afin qu'ils puissent devenir des Top Customer. Compte tenu de leur sensibilité aux promotions, une piste serait de leur proposer des opérations promotionnelles exclusives et ciblées afin de stimuler leurs achats.

CLIENTS DILEMMES



⇒ Notre but n'est pas de les fidéliser ni de changer leurs habitudes de consommation, mais d'augmenter leur nombre, ce qui permettra de générer un chiffre d'affaires plus important. Pour ce faire nous proposons de communiquer sur les articles à succès (articles de modes, beauté, mobiles et tablettes).

CLIENTS À SURVEILLER



⇒ Ce sont d'anciens clients à potentiel élevé qui ont cessé de consommer. Exception faite des mobiles et tablettes qui présentent des volumes de ventes et un taux d'annulation particulièrement élevés, les achats s'orientent vers d'autres catégories peu sujettes à promotions (mens' fashion et Soghaat). Nous proposons ainsi de communiquer sur des produits d'appels, et des nouveautés sur ces catégories afin de reconquérir ces clients.

V. Description des travaux réalisés

1. Organisation de l'équipe

Afin de mener à bien le projet, dans une logique d'échange entre chacun des membres, et de consensus dans la prise de décisions quant aux décisions structurantes, nos travaux ont principalement été réalisés lors de sessions de travail pluri-hebdomadaires.

2. Problématiques rencontrées lors du projet

a. Problématiques scientifiques

Dans les premiers mois du projet, nous avons rencontré des difficultés dans la compréhension et l'appropriation de la mise en œuvre d'une démarche RFM. Cette difficulté a eu pour conséquence de nous égarer dans l'orientation de nos travaux, notamment lors de la réalisation de la phase d'étude statistique / data story telling.

Notre problématique a été d'identifier la variable cible : le client qui, compte tenu du caractère comportementaliste d'une démarche RFM, est au cœur de l'analyse.

b. Gestion des tâches et du jeu de données

La mise en œuvre du preprocessing, et notamment le nettoyage des données a représenté plus d'un tiers du temps consacré au projet.

Par ailleurs l'interprétation des différentes variables (signification des acronymes...) nous a par ailleurs demandé un travail important.

c. Compétences techniques et théoriques

Compte tenu du caractère nouveau des compétences acquises dans le cadre de la formation, nous avons été limités dans la génération de certains éléments (dataviz, connaissances en matière de codage...).

Nous avons par ailleurs eu recours, pour le traitement des taux de conversions à une API, sujet qui n'est pas abordé dans la formation.

d. Limitations liées aux ressources IT

Si nous n'avons pas été confronté à des difficultés majeures sur ce qui relève de notre équipement informatique, il apparaît néanmoins que certaines entrées présentent un temps de traitement important.

Nous visons particulièrement la partie relative au traitement du taux de change et à la réalisation du clustering qui demandent chacune plusieurs minutes de temps de traitement.

Afin de palier à ce défaut dans le cadre de la présentation de l'examen, le découpage des notebooks par phase apporte également une réponse en permettant ainsi d'éviter de réaliser l'intégralité des requêtes et notamment ces requêtes plus longues en temps de traitement.

VI. Bilan & Suite du projet

1. Intérêt scientifique du projet

Afin de répondre aux objectifs du projet, nous avons effectué de nombreuses recherches sur diverses sources d'informations.

En ce sens le projet nous a permis un accroissement de nos connaissances en matière de code, de visualisation, de solutionnement des problématiques de codage.

Par ailleurs, ce projet nous a permis également de découvrir une méthode marketing qu'aucun de nous ne connaissait initialement.

2. Réussite et bilan

Au vu des objectifs initialement fixés, nous tirons le bilan présenté ci-après :

- Nettoyage du dataset : cet objectif a été atteint ;
- Etude des différentes variables : afin d'explorer le data set, nous avons mis en œuvre sur différentes variables considérées comme des cibles potentielles : une étude statistique, une démarche de data story telling, de data visualisation, ainsi qu'un algorithme de régression linéaire ;
- Mise en œuvre d'une méthode RFM : nous avons testé deux modèles RFM afin de n'en retenir qu'un.

Par ailleurs, afin de répondre à notre objectif final qui était de proposer des stratégies, principalement marketing, permettant au site de développer son chiffre d'affaires, nous avons analysé les différents clusters issus de la mise en œuvre de notre démarche RFM pour effectuer des recommandations concrètes.

Ces recommandations pourraient encore être affinées par le biais d'un échange avec des professionnels du marketing. Le modèle RFM proposé nous a permis de percevoir un champ des possibles plus large que le seul modèle présenté ici.

3. Possibilité de mise en œuvre dans en entreprise

Notre modèle nous apparait comme concret, flexible et personnalisable à volonté. Par ailleurs il reste relativement simple à appliquer et mettre en œuvre au sein d'entreprises de divers secteurs.

La démarche appliquée et le modèle qui en résulte ne se limitent pas à la seule application qui en est faite ici. Il est tout à fait possible de l'adapter à de nombreux autres sujets (classification en trois composantes différentes de celles de la RFM).

4. Axes de développements futurs

Il serait possible d'améliorer la méthode d'analyse proposée en comparant par exemple l'évolution des clusters par mois, trimestre, par année... afin d'affiner l'analyse de l'évolution au fil du temps des profils clients.

Il conviendrait également d'approfondir les analyses effectuées et de **perfectionner les data visualisations présentées**. Certaines composantes encore non exploitées dans l'étude des clusters permettraient **d'affiner les résultats et les recommandations formulées**. Par exemple il aurait été possible d'étudier les relations entre les id_clients et Sales_commissions_codes (id magasin), entre les id_clients et les moyens de paiement...

Bibliographie

[RFM ranking – An effective approach to customer segmentation](#)

[Pakistan's Largest E-Commerce Dataset](#)

[Source l'API - Taux de change](#)

[Segmentation RFM et 1ère approche](#)

[2ème approche RFM](#)